

# Lista 3 - Econometria II

Guilherme Argentieri

June 2025

## Questão 1

(a)

A função de verossimilhança é dada por:

$$L(\theta, x_0|x) = \prod_{i=1}^n \theta x_0^\theta x_i^{-\theta-1} = \theta^n x_0^{n\theta} \left( \prod_{i=1}^n x_i \right)^{-\theta-1}$$

Aplicando o logaritmo natural, obtemos a seguinte função log-verossimilhança:

$$\ln(L(\theta, x_0|x)) = n \ln(\theta) + n\theta \ln(x_0) - (\theta + 1) \sum_{i=1}^n \ln(x_i)$$

Note que a função de verossimilhança é crescente em  $x_0$ , mas deve cumprir  $x_i > x_0 \forall i = 1, \dots, n$ . Logo, o valor máximo de  $x_0$  que satisfaz essa condição é:

$$\hat{x}_0 = \min(x_1, \dots, x_n)$$

Agora, para achar o estimador para  $\theta$ , vamos derivar a log-verossimilhança em relação a  $\theta$  e igualar a 0:

$$\begin{aligned} \frac{\partial \ln L(\theta)}{\partial \theta} &= \frac{n}{\theta} + n \ln x_0 - \sum_{i=1}^n \ln x_i = 0 \\ \frac{n}{\hat{\theta}} &= \sum_{i=1}^n \ln x_i - n \ln x_0 \\ \frac{n}{\hat{\theta}} &= \sum_{i=1}^n \ln \left( \frac{x_i}{x_0} \right) \\ \therefore \hat{\theta}_{MV} &= \frac{n}{\sum_{i=1}^n [\ln(x_i) - \ln(\hat{x}_0)]} \end{aligned}$$

Verificando a segunda derivada:

$$\frac{\partial^2 \ln(L(\theta|x))}{\partial \theta^2} = -\frac{n}{\theta^2} < 0$$

Como a segunda derivada é negativa, então o ponto crítico é um máximo.

(b)

A função de verossimilhança é dada por:

$$L(\theta|x) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{[0,\theta]}(x_i) = \theta^{-n} \prod_{i=1}^n \mathbf{1}_{[0,\theta]}(x_i)$$

Note que:

$$L(\theta|x) = \begin{cases} \theta^{-n}, & \text{se } \max(x_1, \dots, x_n) \leq \theta \\ 0, & \text{caso contrário} \end{cases}$$

$\theta^{-n}$  é uma função decrescente em  $\theta$ , logo,  $L(\theta|x)$  é maximizada quando atinge seu menor valor que satisfaz  $\theta \geq \max(x_1, \dots, x_n)$ . Portanto, o estimador de máxima verossimilhança é dado por:

$$\hat{\theta}_{MV} = \max(x_1, \dots, x_n)$$

Obtendo a CDF de  $\hat{\theta}_{MV}$ :

$$F_{\hat{\theta}}(t) = P[\max(x_1, \dots, x_n) \leq t] = P(x_1 \leq t, x_2 \leq t, \dots, x_n \leq t)$$

Note que:

$$P(x_i \leq t) = \begin{cases} 0, & \text{se } t < 0 \\ \frac{t}{\theta}, & \text{se } t \in [0, \theta] \\ 1, & \text{se } t > \theta \end{cases}$$

Então, para  $t \in [0, \theta]$ , temos:

$$F_{\hat{\theta}}(t) = \left(\frac{t}{\theta}\right)^n$$

Derivando em relação a  $t$ , obtemos a densidade:

$$f_{\hat{\theta}}(t) = \frac{dF_{\hat{\theta}}(t)}{dt} = n \frac{t^{n-1}}{\theta^n}$$

Com isso, calculamos a esperança de  $\hat{\theta}_{MV}$ :

$$\begin{aligned} \mathbb{E}[\hat{\theta}_{MV}] &= \int_0^{\theta} t \cdot n \frac{t^{n-1}}{\theta^n} dt \\ &= \frac{n}{\theta^n} \int_0^{\theta} t^n dt \\ &= \frac{n}{\theta^n} \left[ \frac{t^{n+1}}{n+1} \right]_0^{\theta} \\ &= \frac{n}{\theta^n} \frac{\theta^{n+1}}{n+1} \\ &= \theta \frac{n}{n+1} \end{aligned}$$

Note que  $\mathbb{E}[\hat{\theta}_{MV}] \neq \theta$ , portanto, o estimador é viesado.

(c)

A função de verossimilhança é dada por:

$$L(\beta_1, \beta_2 | x) = \prod_{i=1}^n \frac{1}{\beta_2 - \beta_1} \mathbf{1}_{[\beta_1, \beta_2]}(x_i) = (\beta_2 - \beta_1)^{-n} \prod_{i=1}^n \mathbf{1}_{[\beta_1, \beta_2]}(x_i)$$

Para que  $L(\beta_1, \beta_2 | x)$ , é necessário  $\beta_1 \leq \min(x_1, \dots, x_n)$  e  $\beta_2 \geq \max(x_1, \dots, x_n)$ , Note que  $(\beta_2 - \beta_1)^{-n}$  é decrescente em  $(\beta_2 - \beta_1)$ , logo,  $L(\beta_1, \beta_2 | x)$  é maximizada quando  $(\beta_2 - \beta_1)$  atinge seu menor valor. Portanto,

$$\begin{aligned}\hat{\beta}_{1MV} &= \min(x_1, \dots, x_n) \\ \hat{\beta}_{2MV} &= \max(x_1, \dots, x_n)\end{aligned}$$

## Questão 4

(a)

A função de verossimilhança é dada por:

$$L(\beta) = \prod_{i=1}^n \frac{e^{-x_i \beta} e^{x_i \beta y_i}}{y_i!}$$

Aplicando o log, obtemos:

$$\ell(\beta) = \ln(L(\beta)) = \sum_{i=1}^n (e^{-x_i \beta} + \beta x_i y_i - y_i!)$$

(b)

Derivando e igualando a zero:

$$\frac{\partial \ell(\beta)}{\partial \beta} = \sum_{i=1}^n (x_i y_i - x_i e^{x_i \beta}) = 0$$

Note que não há solução analítica fechada para o estimador. Portanto, a CPO que caracteriza o estimador é:

$$\sum_{i=1}^n x_i (y_i - e^{x_i \hat{\beta}_{MV}}) = 0$$

(c)

Avaliando a segunda derivada da função log-verossimilhança:

$$\frac{\partial^2 \ell(\beta)}{\partial \beta^2} = \sum_{i=1}^n (-x_i^2 e^{x_i \beta}) < 0 \quad \forall x_i, \beta$$

Dado que o estimador de máxima verossimilhança satisfaz a CPO e que a segunda derivada da função log-verossimilhança é sempre negativa, a função é estritamente côncava, o que garante que  $\hat{\beta}_{MV}$  maximiza a função de máxima verossimilhança.

(d)

A matriz de informação de Fisher é dada por:

$$I(\beta) = -\mathbb{E} \left[ \frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^T} \right]$$

Do exercício anterior, teremos:

$$I(\beta) = -\mathbb{E} \left[ \sum_{i=1}^n (-x_i^2 e^{x_i \beta}) \right] = \sum_{i=1}^n x_i x_i^T e^{x_i \beta}$$

Portanto, sob as condições de regularidade, temos que:

$$\sqrt{n}(\hat{\beta}_{MV} - \beta_0) \xrightarrow{d} \mathcal{N}(0, I^{-1}(\beta_0))$$

## Questão 7

(a)

A função de verossimilhança é dada por:

$$L(y_i; x_i; \beta) = \prod_{i=1}^n \frac{1}{\beta + x_i} e^{-\frac{y_i}{\beta + x_i}}$$

Aplicando o log, obtemos a seguinte log-verossimilhança:

$$\ell(\beta) = \sum_{i=1}^n \left( -\frac{y_i}{\beta + x_i} - \log(\beta + x_i) \right) = -\sum_{i=1}^n \left( \frac{y_i}{\beta + x_i} + \log(\beta + x_i) \right)$$

(b)

Derivando e igualando a zero:

$$\frac{\partial \ell(\beta)}{\partial \beta} = -\sum_{i=1}^n \left[ -\frac{y_i}{(\beta + x_i)^2} + \frac{1}{\beta + x_i} \right] = 0 \Rightarrow \sum_{i=1}^n \left[ \frac{(\beta + x_i) - y_i}{(\beta + x_i)^2} \right] = 0$$

Note que não há solução analítica fechada para  $\beta$ . Logo, a CPO que caracteriza o estimador é:

$$\sum_{i=1}^n \left[ \frac{(\hat{\beta}_{MV} + x_i) - y_i}{(\hat{\beta}_{MV} + x_i)^2} \right] = 0$$

(c)

Para este item, será utilizado o método de Newton-Raphson, que utilizará o seguinte mecanismo para cada iteração:

$$\beta_{k+1} = \beta_k - \left[ \frac{\partial^2 \ell(\beta)}{\partial \beta^2} \right]^{-1} \cdot \left[ \frac{\partial \ell(\beta)}{\partial \beta} \right]$$

```
library(readxl)

dados_q7 <- read_excel("data_PS3.xlsx", sheet = 'data-q5')
beta <- 1 #Valor inicial da estimação por Newton Ralphson
y <- as.numeric(dados_q7$Renda)
x <- as.numeric(dados_q7$Educ)

for(k in 1:10) {
  #Calculando as derivadas
  d1 <- sum( -1/(beta + x) + y/(beta + x)^2 )
  d2 <- sum( 1/(beta + x)^2 - 2*y/(beta + x)^3 )

  # update pelo passo de Newton
  beta <- beta - d1/d2
  cat("iteração", k, "-> beta =", beta, "\n")
}

## iteração 1 -> beta = 5.085934
## iteração 2 -> beta = 8.695518
## iteração 3 -> beta = 10.66269
## iteração 4 -> beta = 11.07962
## iteração 5 -> beta = 11.09468
## iteração 6 -> beta = 11.0947
## iteração 7 -> beta = 11.0947
## iteração 8 -> beta = 11.0947
## iteração 9 -> beta = 11.0947
## iteração 10 -> beta = 11.0947
```

## Questão 8

##(c)

```
library(AER)
library(gmm)

#Extraindo os dados
dados_q8 <- read_excel("data_PS3.xlsx", sheet = "data-q6")
y <- as.numeric(dados_q8$Y)
x <- as.numeric(dados_q8$X)
z <- as.numeric(dados_q8$Z)

#MQ2E (IV)
```

```

model_iv <- ivreg(y ~ x | z)
beta_iv <- coef(model_iv)

#GMM

gmm_iv <- gmm(y~x, x = z, wmatrix = 'optimal')
beta_gmm_iv <- coef(gmm_iv)

print(beta_iv)

```

```

## (Intercept)          x
##      9.36912      3.06382

```

```
print(beta_gmm_iv)
```

```

## (Intercept)          x
##      9.36912      3.06382

```

(d)

Temos o modelo linear  $y_i = x_i' \beta + \varepsilon_i$ , podendo ser reescrito como  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$  se considerarmos  $Y_i = y_i$ ,  $x_i' = (1 \ X_i)$  e  $\varepsilon_i = \varepsilon$ . Ademais, consideraremos  $z_i = (1 \ Z_i \ Z_i^2 \ Z_i^3)$ . A função momento para GMM com instrumentos  $z_i$  é dada por:

$$g(w_i, \beta) = z_i \cdot (Y_i - \beta_0 - \beta_1 X_i) = \begin{pmatrix} 1 \\ Z_i \\ Z_i^2 \\ Z_i^3 \end{pmatrix} \cdot (Y_i - \beta_0 - \beta_1 X_i) = \begin{bmatrix} (Y_i - \beta_0 - \beta_1 X_i) \\ Z_i(Y_i - \beta_0 - \beta_1 X_i) \\ Z_i^2(Y_i - \beta_0 - \beta_1 X_i) \\ Z_i^3(Y_i - \beta_0 - \beta_1 X_i) \end{bmatrix}$$

Portanto, as condições de momento são:

$$\mathbb{E} \left[ \begin{pmatrix} 1 \\ Z_i \\ Z_i^2 \\ Z_i^3 \end{pmatrix} \cdot (Y_i - \beta_0 - \beta_1 X_i) \right] = 0$$

(e)

```

z_2 <- z^2
z_3 <- z^3

iv_8e <- ivreg(y ~ x | z + z_2 + z_3)
gmm_8e <- gmm(y ~ x, ~ z + z_2 + z_3, wmatrix = 'optimal')

print(coef(iv_8e))

```

```

## (Intercept)          x
##      9.919521      2.067385

```

```
print(coef(gmm_8e))
```

```
## (Intercept)          x
##      9.911935      2.072861
```

É possível que o estimador de GMM seja similar ao de 2SLS desde que definamos a matriz de pesos como  $W_n = (Z'Z)^{-1}$

(f)

```
library(tidyverse)
j_test <- (gmm_8e %>% summary)$stest
print(j_test)
```

```
##
## ## J-Test: degrees of freedom is 2 ##
##
##          J-test    P-value
## Test E(g)=0:    2.51088  0.28495
```

Dado que o p-valor é maior que o nível de significância, há evidências para rejeitarmos a hipótese nula, ou seja, temos indicativos de que as condições de ortogonalidade não são inválidas.

## Questão 9

Substituindo  $W_n = \Phi^{-1}$ :

$$\begin{aligned} V &= (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} (\Sigma'_{ZX} \underbrace{\Phi^{-1} \Phi}_I \Phi^{-1} \Sigma_{ZX}) (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} \\ &\Rightarrow V = \underbrace{(\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})}_I (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} \\ &\therefore V = (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} = V_0 \end{aligned}$$

(b)

Defina  $B$  como  $B = \Phi^{-1} \Sigma_{ZX} (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1}$ . Assim, podemos fazer a verificação:

$$\begin{aligned} B' \Phi B &= [\Phi^{-1} \Sigma_{ZX} (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1}]' \Phi [\Phi^{-1} \Sigma_{ZX} (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1}] \\ &= [(\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1}]' \Sigma'_{ZX} \underbrace{\Phi^{-1} \Phi}_I \Phi^{-1} \Sigma_{ZX} (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} \\ &= [(\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1}]' \Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX} (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} \\ &= (\Sigma'_{ZX} \Phi^{-1} \Sigma_{ZX})^{-1} = V_0 \end{aligned}$$

Defina  $A$  como  $A = W_n \Sigma_{ZX} (\Sigma'_{ZX} W_n \Sigma_{ZX})^{-1}$ . Assim, podemos fazer a verificação:

$$\begin{aligned} A' \Phi A &= [W_n \Sigma_{ZX} (\Sigma'_{ZX} W_n \Sigma_{ZX})^{-1}]' \Phi W_n \Sigma_{ZX} (\Sigma'_{ZX} W_n \Sigma_{ZX})^{-1} \\ &= (\Sigma'_{ZX} W_n \Sigma_{ZX})^{-1} \Sigma'_{ZX} W_n \Phi W_n \Sigma_{ZX} (\Sigma'_{ZX} W_n \Sigma_{ZX})^{-1} = V \end{aligned}$$

(c)

$$\begin{aligned} B'\Phi A &= [\Phi^{-1}\Sigma_{ZX}(\Sigma'_{ZX}\Phi^{-1}\Sigma_{ZX})^{-1}]'\Phi W_n\Sigma_{ZX}(\Sigma'_{ZX}W_n\Sigma_{ZX})^{-1} \\ &= [(\Sigma'_{ZX}\Phi^{-1}\Sigma_{ZX})^{-1}]'\Sigma'_{ZX}\underbrace{\Phi^{-1}\Phi}_I W_n\Sigma_{ZX}(\Sigma'_{ZX}W_n\Sigma_{ZX})^{-1} \\ &= [(\Sigma'_{ZX}\Phi^{-1}\Sigma_{ZX})^{-1}]'\Sigma'_{ZX}\underbrace{W_n}_{\Phi^{-1}}\Sigma_{ZX}(\Sigma'_{ZX}W_n\Sigma_{ZX})^{-1} \\ &= (\Sigma'_{ZX}\Phi^{-1}\Sigma_{ZX})^{-1} = B'\Phi B \end{aligned}$$

Logo, podemos notar que:

$$B'\Phi A = B'\Phi B \Rightarrow B'\Phi A - B'\Phi B = 0 \Rightarrow B'\Phi(A - B) = 0$$

(d)

Sabemos que a matriz  $\Phi$  é positiva definida, pois, caso não fosse, o estimador de GMM não estaria bem definido. Portanto, podemos escrever a matriz como  $\Phi = \Phi^{\frac{1}{2}}\Phi^{\frac{1}{2}}$ . Ademais, vamos definir  $C := \Phi^{\frac{1}{2}}A$  e  $D := \Phi^{\frac{1}{2}}B$ . Com isso, sabemos que  $V = C'C$  e  $V_0 = D'D$ , também sabemos do item anterior que  $D'C = D'D = V_0$ . Com isso, temos:

$$V - V_0 = C'C - D'D$$

Dado que  $D'C = D'D$ , podemos substituir isso na equação e manipular da seguinte forma:

$$V - V_0 = C'C - D'C + C'D - D'D = (C - D)'(C - D)$$

Dado que o produto de uma matriz pela sua transposta é uma matriz positiva semi-definida, concluímos que:

$$V - V_0 = (C - D)'(C - D) \therefore V - V_0 \geq 0$$

## Questão 10

(a)

No sistema, há duas variáveis endógenas ( $X$  e  $Y$ ) e apenas uma variável exógena ( $Z$ ). Na equação 1, o número de variáveis exógenas excluídas (zero) é maior do que o número de variáveis endógenas no sistema menos um ( $2 - 1 = 1$ ), o que viola o critério da ordem, logo,  $\beta_2$  não é identificado. Já na segunda equação, o número de variáveis exógenas excluídas (1) é igual ao número de variáveis endógenas do sistema menos um ( $2 - 1 = 1$ ), portanto,  $\alpha_2$  é identificado

(b)

É possível estimar  $\alpha_2$  usando  $Z$  como instrumento utilizando a condição de momento  $\mathbb{E}[ZV] = 0$ . Sendo seu análogo amostral dado por  $\frac{1}{n} \sum_{i=1}^n Z_i V_i$ . além disso, note que,  $\mathbb{E}[V_i] = 0 \Rightarrow \mathbb{E}[X_i - \alpha_1 - \alpha_2 Y_i] = 0$  com análogo amostral dado por  $\frac{1}{n} \sum_{i=1}^n (X_i - \alpha_1 - \alpha_2 Y_i)$

Dado que existem dois parâmetros e dois momentos, o modelo está exatamente identificado. Os parâmetros podem ser estimados resolvendo o sistema:



$$\begin{cases} \sum_{i=1}^n Z_i(X_i - \alpha_1 - \alpha_2 Y_i) = 0 \\ \sum_{i=1}^n (X_i - \alpha_1 - \alpha_2 Y_i) = 0 \end{cases}$$